

# Inferência Bayesiana para os parâmetros da distribuição Weibull Estendida de Marshall–Olkin

André F. B. Menezes

Universidade Estadual de Maringá

Departamento de Estatística

7 de Novembro de 2017

# Organização

- ① Introdução
- ② Função de Verossimilhança
- ③ Inferência Bayesiana
- ④ Aplicações
  - Aplicação I
  - Aplicação II

# Introdução

## Método de Marshall-Olkin (1997)

$$\begin{aligned}S(x \mid \theta, \alpha) &= \frac{\alpha S_1(x \mid \theta)}{1 - \bar{\alpha} S_1(x \mid \theta)}, \\f(x \mid \theta, \alpha) &= \frac{\alpha f_1(x \mid \theta)}{[1 - \bar{\alpha} S_1(x \mid \theta)]^2}, \\h(x \mid \theta, \alpha) &= \frac{h_1(x \mid \theta)}{1 - \bar{\alpha} S_1(x \mid \theta)}\end{aligned}$$

em que  $\alpha > 0$  é o novo parâmetro denominado de *tilt*,  $S_1(x \mid \theta)$ ,  $f_1(x \mid \theta)$  e  $h_1(x \mid \theta)$  são as funções sobrevivência, densidade e risco da distribuição base, respectivamente.

# Introdução



## Distribuição Weibull Estendida de Marshall–Olkin (MOEW)

$$\begin{aligned}S(x \mid \lambda, \alpha, \beta) &= \frac{\alpha e^{-(\lambda x)^\beta}}{1 - \bar{\alpha} e^{-(\lambda x)^\beta}}, \\f(x \mid \lambda, \alpha, \beta) &= \frac{\alpha \beta \lambda^\beta x^{\beta-1} e^{-(\lambda x)^\beta}}{\left[1 - \bar{\alpha} e^{-(\lambda x)^\beta}\right]^2}, \\h(x \mid \lambda, \alpha, \beta) &= \frac{\beta \lambda^\beta x^{\beta-1}}{1 - \bar{\alpha} e^{-(\lambda x)^\beta}}\end{aligned}$$

$\lambda > 0$  é o parâmetro de taxa ( $1/\mu$ ),  $\beta > 0$  e  $\alpha > 0$  governam a forma das funções de densidade e risco.



# Introdução

## Função densidade de probabilidade



# Introdução

## Função de risco



# Introdução

## Casos particulares

- ▶  $0 < \alpha < 1 \rightarrow$  distribuição Weibull-Geométrica.
- ▶  $\alpha = 1 \rightarrow$  distribuição Weibull.
- ▶  $\beta = 1 \rightarrow$  distribuição Exponencial Estendida de Marshall–Olkin.
- ▶  $\alpha = \beta = 1 \rightarrow$  distribuição Exponencial.

# Função de Verossimilhança

## Dados completos

Seja  $\mathbf{x} = (x_1, x_2, \dots, x_n)^\top$  uma amostra aleatória e da distribuição MOEW.

► Função de verossimilhança:

$$L(\boldsymbol{\theta} \mid \mathbf{x}) = \prod_{i=1}^n f(x_i \mid \boldsymbol{\theta}) = \prod_{i=1}^n \frac{\alpha \beta \lambda^\beta x_i^{\beta-1} e^{-(\lambda x_i)^\beta}}{\left[1 - \bar{\alpha} e^{-(\lambda x_i)^\beta}\right]^2}.$$



# Função de Verossimilhança

## Dados com censura intervalar

Considere que  $\delta_i = 1$  se a observação não foi censurada e  $\delta_i = 0$  se a observação é censurada por intervalo.

- Função de verossimilhança:

$$L(\boldsymbol{\theta} \mid \boldsymbol{t}, \{\boldsymbol{l}, \boldsymbol{r}\}, \boldsymbol{\delta}) = \prod_{i=1}^n [f(t_i \mid \boldsymbol{\theta})]^{\delta_i} [S(l_i \mid \boldsymbol{\theta}) - S(r_i \mid \boldsymbol{\theta})]^{1-\delta_i}.$$

Sendo:

- $\boldsymbol{t} = (t_1, \dots, t_{n_1})$  as  $n_1$  observações exatamente observadas;
- $\{\boldsymbol{l}, \boldsymbol{r}\} = (\{l_{n_1+1}, r_{n_1+1}\}, \dots, \{l_{n_2}, r_{n_2}\})$  as  $n_2$  observações com censura intervalar;

# Inferência Bayesiana

## Distribuição a posteriori

Toda inferência Bayesiana se concentra na distribuição a posteriori. A distribuição a posteriori é proporcional a

$$\pi(\boldsymbol{\theta} \mid \text{Dados}) \propto \pi(\boldsymbol{\theta}) L(\boldsymbol{\theta} \mid \text{Dados}),$$

em que:

- ▶  $\boldsymbol{\theta} = (\lambda, \beta, \alpha)^\top$  é o vetor de parâmetros da distribuição MOEW;
- ▶  $\pi(\boldsymbol{\theta})$  é a distribuição a priori conjunta de  $\boldsymbol{\theta}$ ;
- ▶  $L(\boldsymbol{\theta} \mid \text{Dados})$  representa a função de verossimilhança da amostra observada.

# Inferência Bayesiana

## Métodos MCMC

- ▶ A distribuição a posteriori não possui forma fechada.
- ▶ Os métodos de Monte Carlo em Cadeias de Markov (MCMC) foram utilizados para gerar amostras das distribuições marginais posteriori.
- ▶ A cadeia foi gerada considerando 1,000,000 simulações para cada parâmetro.
- ▶ Com um *burn-in* de tamanho 1000.
- ▶ Os valores simulados foram selecionados de 100 em 100.
- ▶ Resultando em amostras finais de tamanho 20,000.
- ▶ A procedure MCMC do SAS foi utilizada.

# Aplicações

## Aplicação I

- Os dados foram simulados utilizando o método da transformação inversa, isto é



$$x_i = \frac{1}{\lambda} \left[ -\log \left( \frac{u_i}{\alpha + \bar{\alpha} u_i} \right) \right]^{1/\beta}, \quad i = 1, \dots, n.$$

em que  $u_i$  são números aleatórios da distribuição uniforme padrão.

- O seguinte cenário foi estabelecido:  $n = (100, 300, 500)$ ,  $\lambda = 1.0$ ,  $\beta = 2.0$  e  $\alpha = 0.1$

# Aplicações

## Aplicação I



# Aplicação I

## Definição das distribuições a priori

- ▶  $\pi(\lambda) \sim \text{Gamma}(0.001; 0.001)$ .
- ▶  $\pi(\beta) \sim \text{Gamma}(0.001; 0.001)$ .
- ▶  $\pi(\alpha) \sim \text{Uniforme}(0; 1)$ .

# Aplicação I

## Estimativas Clássicas e Bayesianas.

$n$	Parâmetro	EMV (E.P.)	Média (D.P.)	IC 95%	HPD 95%
100	$\lambda$	1.8894 (0.5828)	1.8310 (0.3381)	(0.7471, 3.0317)	(1.1490, 2.4374)
	$\beta$	1.4222 (0.2273)	1.4388 (0.1549)	(0.9767, 1.8678)	(1.1568, 1.7507)
	$\alpha$	0.6446 (0.4796)	0.6217 (0.2260)	(-0.2954, 1.5845)	(0.2376, 0.9993)
300	$\lambda$	1.3913 (0.2275)	1.5025 (0.2544)	(0.9455, 1.8372)	(1.0365, 2.0378)
	$\beta$	1.7209 (0.1402)	1.6623 (0.1398)	(1.4460, 1.9957)	(1.4025, 1.9411)
	$\alpha$	0.3082 (0.1405)	0.4062 (0.1802)	(0.0329, 0.5835)	(0.1198, 0.7917)
500	$\lambda$	0.7853 (0.1460)	0.8304 (0.1571)	(0.4990, 1.0715)	(0.5135, 1.1434)
	$\beta$	1.9647 (0.1024)	1.9266 (0.1044)	(1.7639, 2.1655)	(1.7205, 2.1288)
	$\alpha$	0.0697 (0.0349)	0.0898 (0.0458)	(0.0012, 0.1381)	(0.0178, 0.1823)

- Verdadeiros valores dos parâmetros:  $\lambda = 1$ ,  $\beta = 2.0$  e  $\alpha = 0.1$ .

# Aplicação I

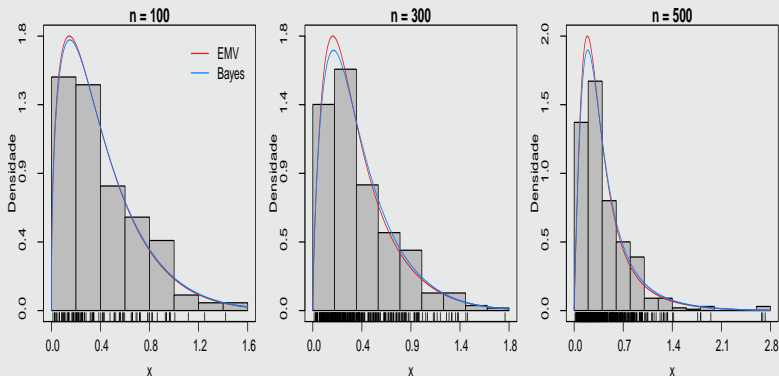
CrITÉRIOS para avaliar a convergência das cadeias ( $n = 100$ ).

Parâmetro	Heidelberger-Welch		Geweke	
	Estatística	valor- $p$	Estatística	valor- $p$
$\lambda$	0.0639	0.7892	-0.8358	0.4033
$\beta$	0.1540	0.3775	-0.3016	0.7629
$\alpha$	0.0665	0.7733	-0.2364	0.8131



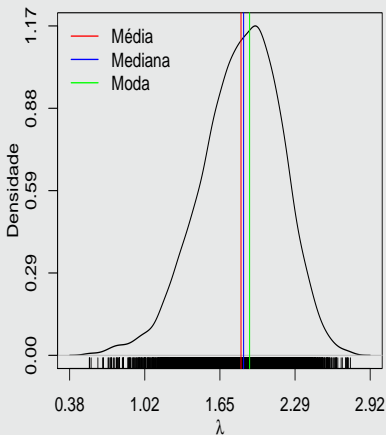

# Aplicação I

## Histograma e curva teórica ajustada.





# Aplicação I

Convergência e densidade a posteriori de  $\lambda$  ( $n = 100$ ).



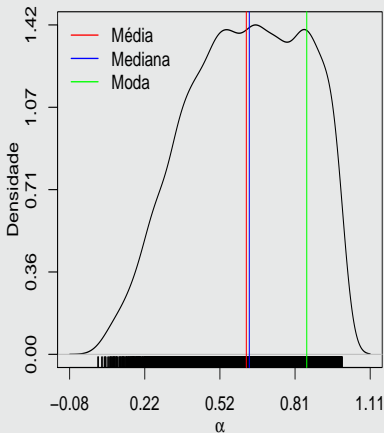

# Aplicação I

Convergência e densidade a posteriori de  $\beta$  ( $n = 100$ ).



# Aplicação I

Convergência e densidade a posteriori de  $\alpha$  ( $n = 100$ ).



## Aplicação II

- ▶ Os dados consistem de um estudo realizado na Dinamarca entre 1993 e 1972 envolvendo 731 pacientes diagnosticados como diabéticos do Tipo I entre 1933 e 1972, e seguidos até a morte, a emigração ou 31 de dezembro de 1984.
- ▶ O tempo de sobrevivência de interesse é o tempo (meses) desde o início da diabetes até o início da nefropatia diabética (DN).
- ▶ Todos os paciente desenvolveram a nefropatia diabética no momento de admissão ou até o final do estudo, logo não há observação censurada a direita.
- ▶ 596 tempos foram exatamente observados e 136 observações apresentaram censura intervalar.
- ▶ Entre os 731 pacientes, têm-se 277 mulheres e 454 homens.

# Aplicação II

## Considerações

- ▶ A distribuição MOEW foi reparametrizada em termos de  $\mu$ , em que  $\lambda = 1/\mu$ .
- ▶  $\pi(\lambda) \sim \text{Gamma}(0.001; 0.001)$ .
- ▶  $\pi(\beta) \sim \text{Gamma}(0.001; 0.001)$ .
- ▶  $\pi(\alpha) \sim \text{Uniforme}(0; 1)$ .

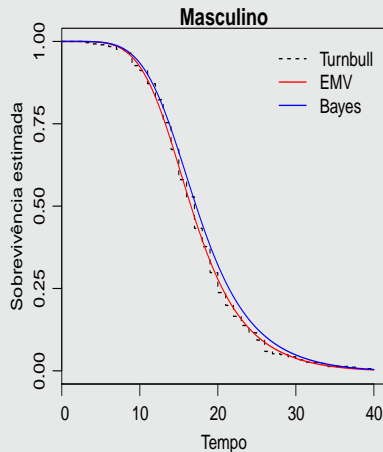
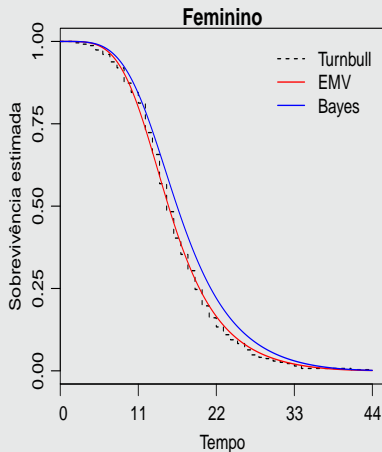
# Aplicação I

## Estimativas Clássicas e Bayesianas.

Modelo	Gênero	Parâmetro	EMV (E.P.)	Média (D.P.)	IC 95%	HPD 95%
MOEW	Feminino	$\mu$	31.5621 (4.1393)	31.3722 (5.1347)	(23.4492, 39.6751)	(23.1008, 40.9715)
		$\beta$	4.1870 (0.2991)	4.0692 (0.3100)	(3.6007, 4.7734)	(3.4488, 4.6691)
		$\alpha$	0.0489 (0.0360)	0.0754 (0.0565)	(-0.0216, 0.1194)	(0.0010, 0.1854)
	Masculino	$\mu$	33.0371 (3.0012)	33.4082 (3.6710)	(27.1548, 38.9194)	(27.4911, 40.7049)
		$\beta$	4.9068 (0.2547)	4.8526 (0.2523)	(4.4076, 5.4059)	(4.3589, 5.3484)
		$\alpha$	0.0343 (0.0197)	0.0410 (0.0226)	(-0.0043, 0.0729)	(0.0032, 0.0852)
Weibull	Feminino	$\mu$	18.0958 (0.4457)	18.1044 (0.4482)	(17.2183, 18.9732)	(17.2491, 19.0029)
		$\beta$	2.6450 (0.1203)	2.6368 (0.1201)	(2.4083, 2.8818)	(2.4070, 2.8771)
	Masculino	$\mu$	19.3296 (0.3357)	19.3346 (0.3375)	(18.6698, 19.9894)	(18.6754, 19.9976)
		$\beta$	2.9583 (0.1062)	2.9533 (0.1065)	(2.7497, 3.1670)	(2.7454, 3.1628)

# Aplicação I



## Curvas de sobrevivência estimadas.





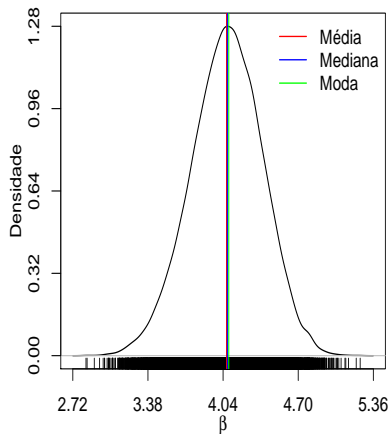

# Convergência e densidade a posteriori de $\mu$ .

- Gênero Feminino



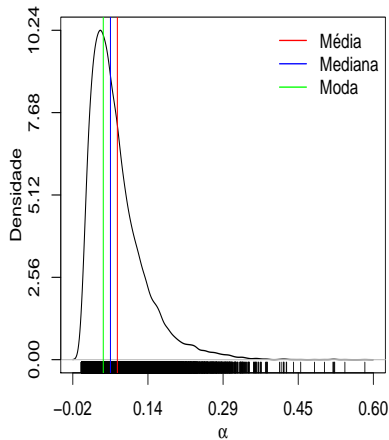

# Convergência e densidade a posteriori de $\beta$ .

- Gênero Feminino



# Convergência e densidade a posteriori de $\alpha$ .

- Gênero Feminino



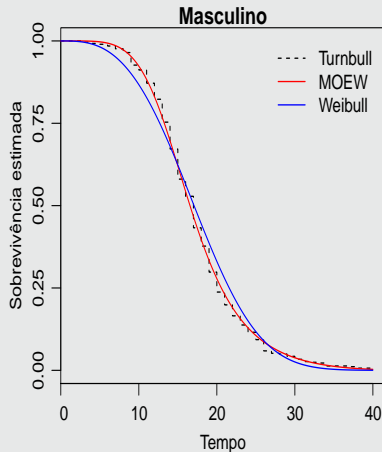
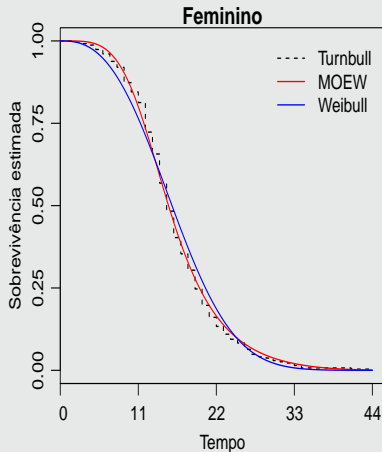
# Aplicação I

## Critérios de discriminação Clássicos e Bayesianos.

Gênero	Modelo	AIC	DIC
Feminino	MOEW	295.2428	285.9942
	Weibull	309.9924	309.9955
Masculino	MOEW	399.3692	393.8040
	Weibull	438.8576	438.8871

# Aplicação I

## Comparação entre as distribuições MOEW e Weibull.



# Referências

- [1] Almalki, S. J., Nadarajah, S., 2014. Modifications of the Weibull distribution: A review. *Reliability Engineering & System Safety* 124 (Supplement C), 32–55.
- [2] Marshall, A. W., Olkin, I., 1997. *A new method for adding a parameter to a family of distributions with application to the exponential and weibull families*. *Biometrika* 84 (3), 641–652.
- [3] SAS, 2010a. *The MCMC Procedure*, SAS/STAT User's Guide, Version 9.4. Cary, NC: SAS Institute Inc.
- [4] SAS, 2010b. *The NLMIXED Procedure*, SAS/STAT User's Guide, Version 9.4. Cary, NC: SAS Institute Inc.